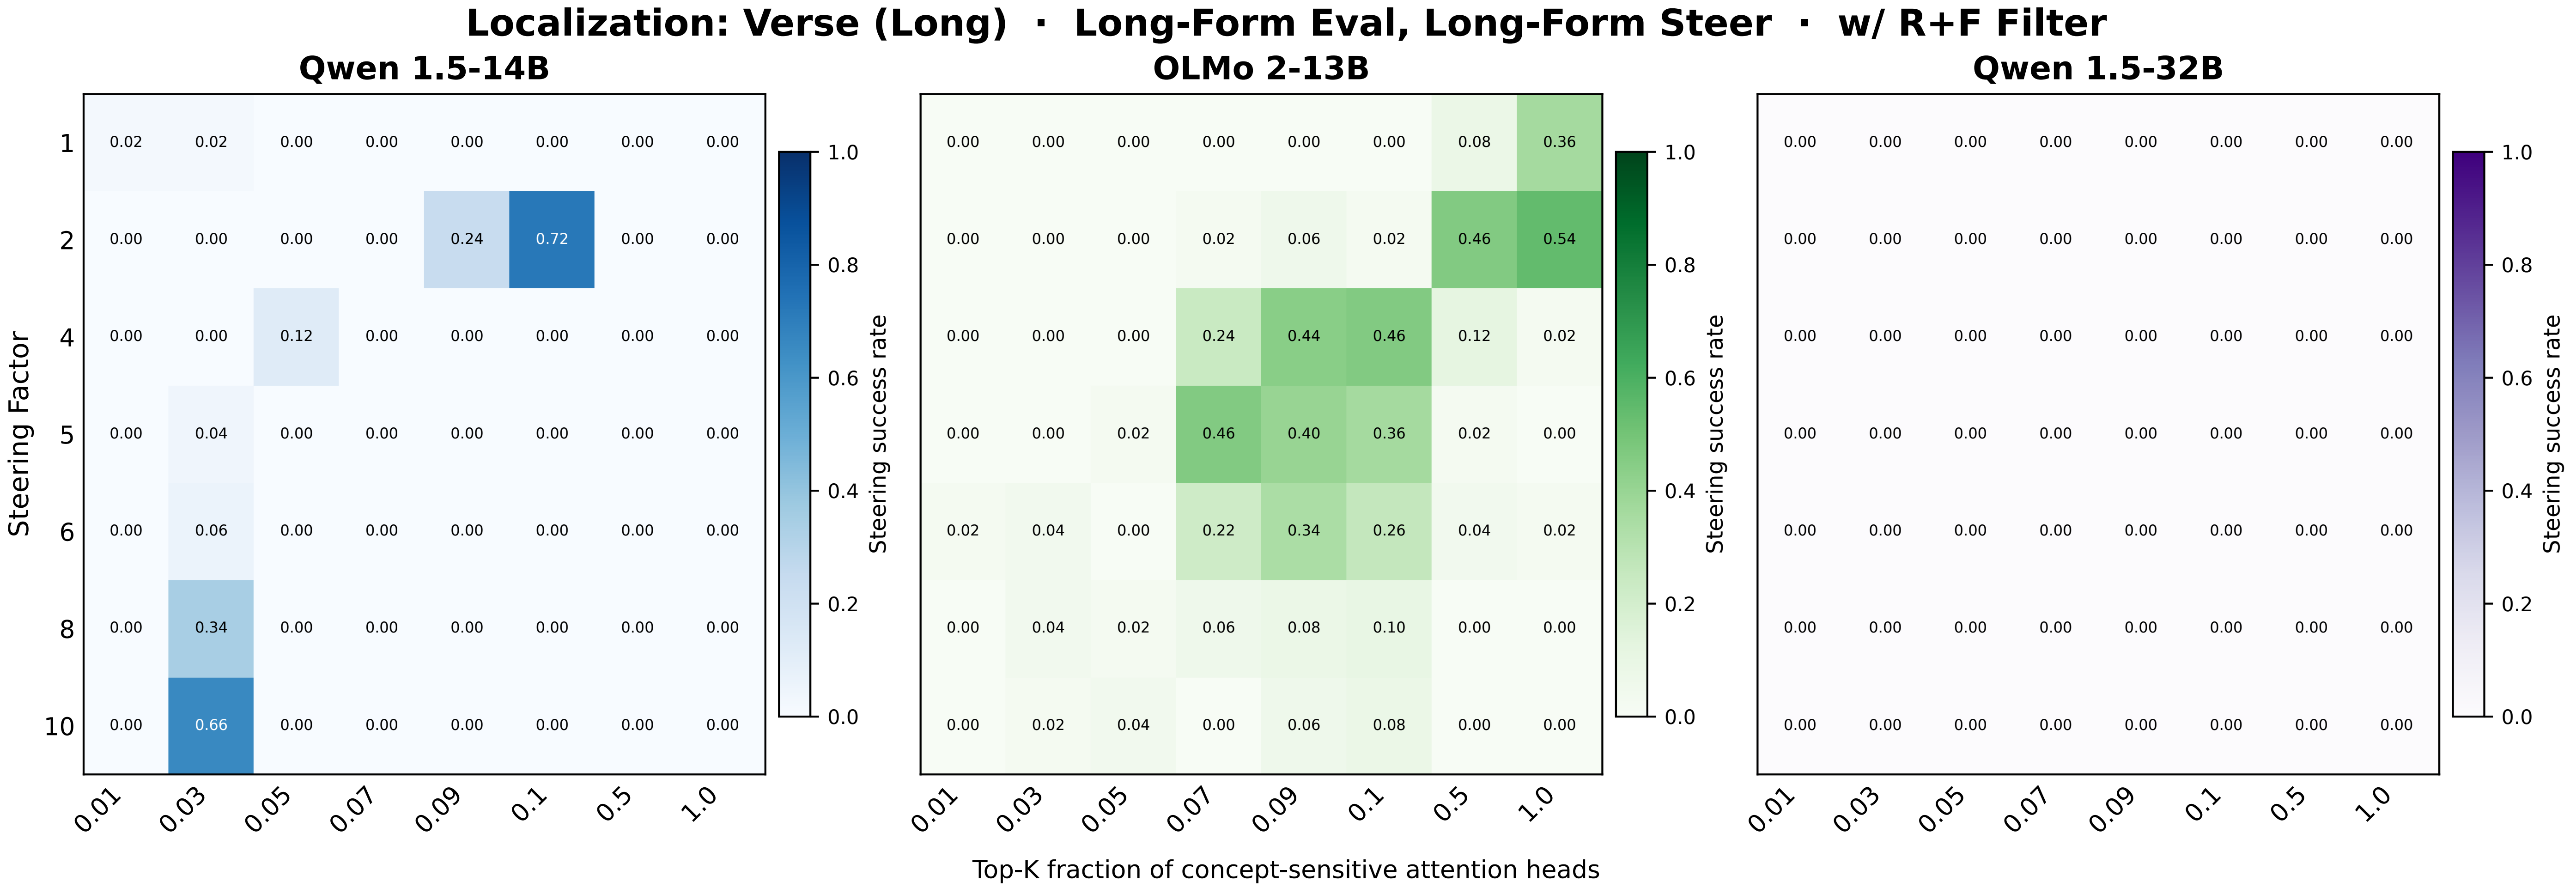
Localization: Verse (Long) · Long-Form Eval, Long-Form Steer · w/ R+F Filter
Qwen 1.5-14B
OLMo 2-13B
Qwen 1.5-32B
Steering Factor
1
2
4
5
6
8
10
Top-K fraction of concept-sensitive attention heads
0.01
0.03
0.05
0.07
0.09
0.1
0.5
1.0
Steering success rate
0.0
0.2
0.4
0.6
0.8
1.0
Qwen 1.5-14B
0.02 0.02 0.00 0.00 0.00 0.00 0.00 0.00
0.00 0.00 0.00 0.00 0.24 0.72 0.00 0.00
0.00 0.00 0.12 0.00 0.00 0.00 0.00 0.00
0.00 0.04 0.00 0.00 0.00 0.00 0.00 0.00
0.00 0.06 0.00 0.00 0.00 0.00 0.00 0.00
0.00 0.34 0.00 0.00 0.00 0.00 0.00 0.00
0.00 0.66 0.00 0.00 0.00 0.00 0.00 0.00
OLMo 2-13B
0.00 0.00 0.00 0.00 0.00 0.00 0.08 0.36
0.00 0.00 0.00 0.02 0.06 0.02 0.46 0.54
0.00 0.00 0.00 0.24 0.44 0.46 0.12 0.02
0.00 0.00 0.02 0.46 0.40 0.36 0.02 0.00
0.02 0.04 0.00 0.22 0.34 0.26 0.04 0.02
0.00 0.04 0.02 0.06 0.08 0.10 0.00 0.00
0.00 0.02 0.04 0.00 0.06 0.08 0.00 0.00
Qwen 1.5-32B
0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00