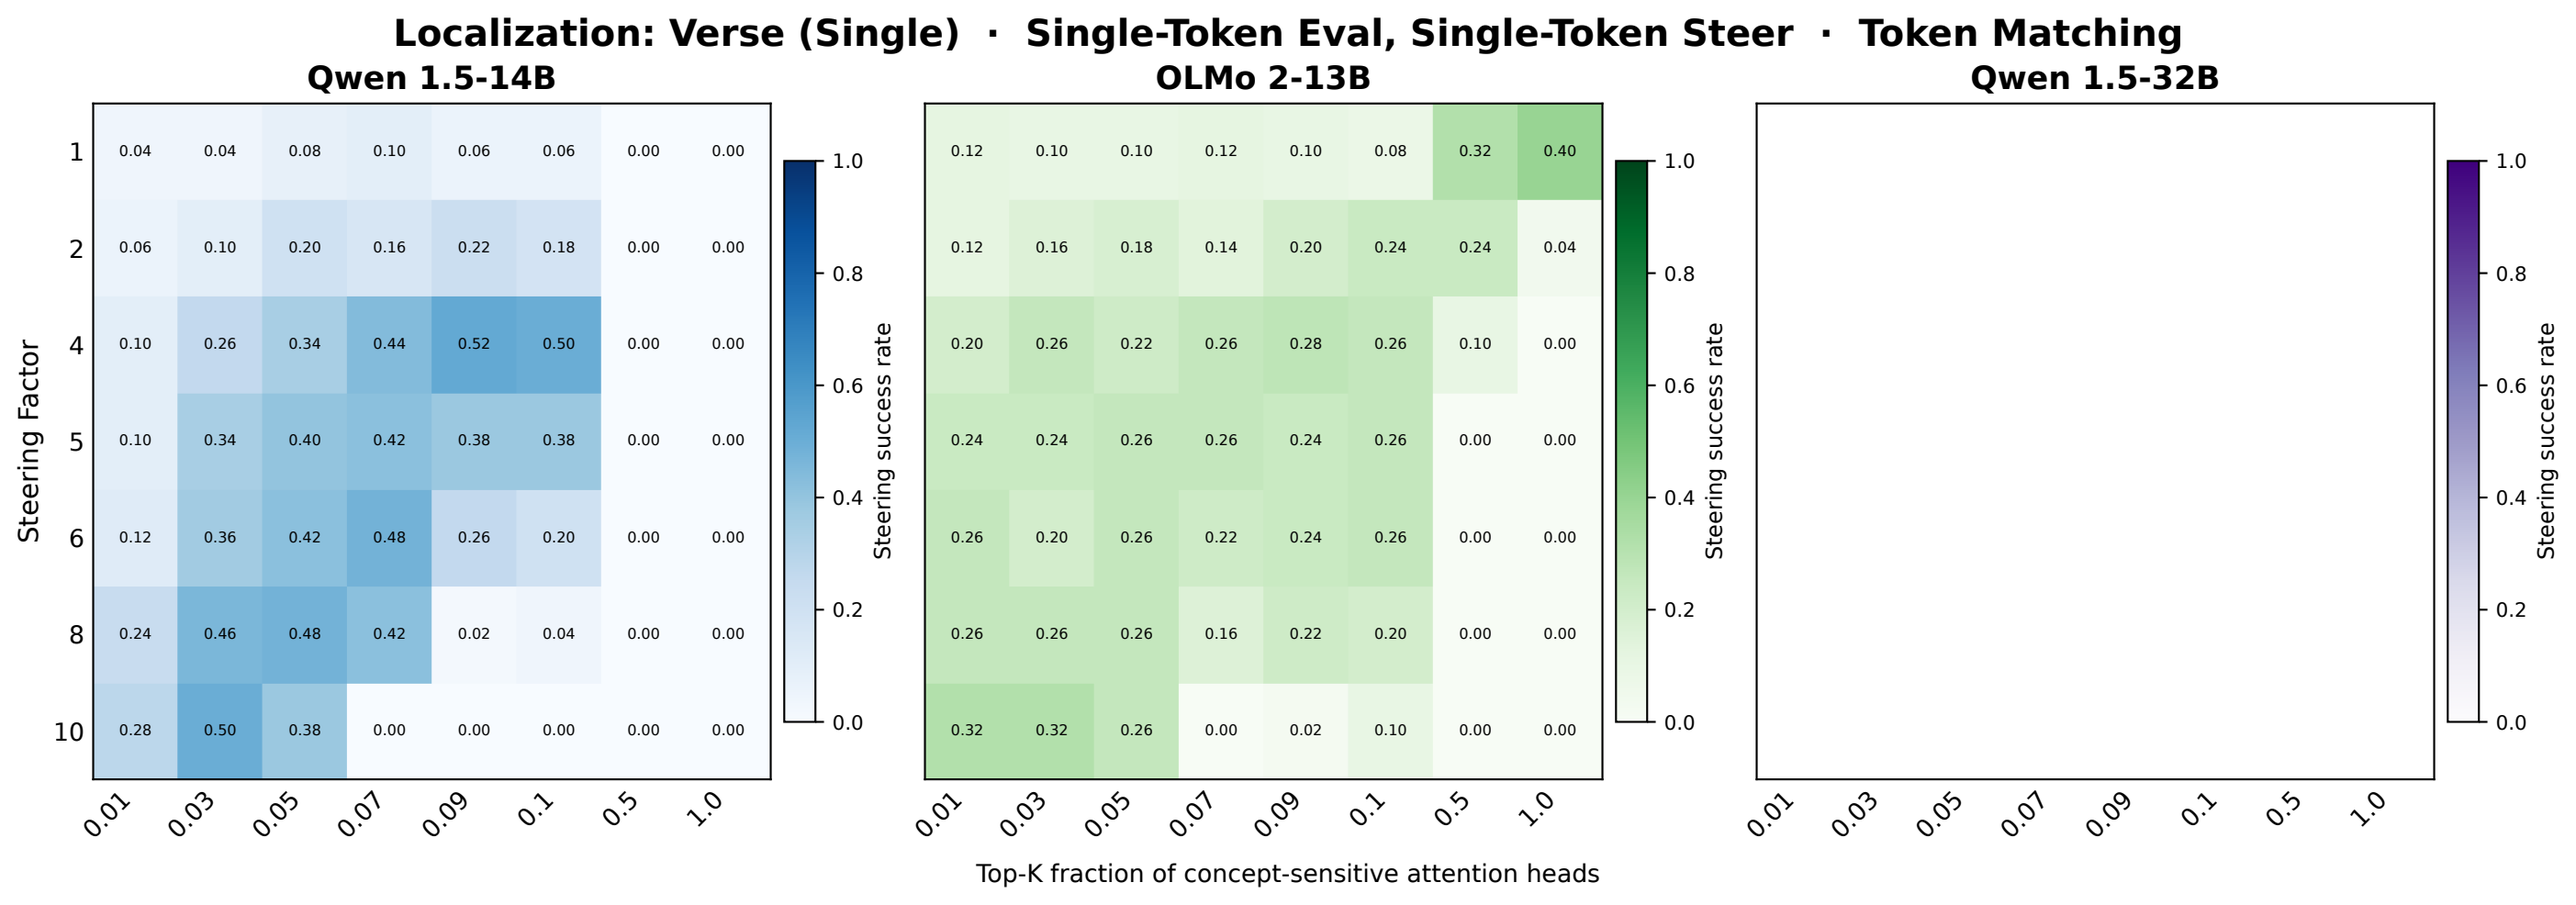

Localization: Verse (Single) · Single-Token Eval, Single-Token Steer · Token Matching
Qwen 1.5-14B
OLMo 2-13B
Qwen 1.5-32B
Steering Factor
1
2
4
5
6
8
10
0.04 0.04 0.08 0.10 0.06 0.06 0.00 0.00
0.06 0.10 0.20 0.16 0.22 0.18 0.00 0.00
0.10 0.26 0.34 0.44 0.52 0.50 0.00 0.00
0.10 0.34 0.40 0.42 0.38 0.38 0.00 0.00
0.12 0.36 0.42 0.48 0.26 0.20 0.00 0.00
0.24 0.46 0.48 0.42 0.02 0.04 0.00 0.00
0.28 0.50 0.38 0.00 0.00 0.00 0.00 0.00
0.12 0.10 0.10 0.12 0.10 0.08 0.32 0.40
0.12 0.16 0.18 0.14 0.20 0.24 0.24 0.04
0.20 0.26 0.22 0.26 0.28 0.26 0.10 0.00
0.24 0.24 0.26 0.26 0.24 0.26 0.00 0.00
0.26 0.20 0.26 0.22 0.24 0.26 0.00 0.00
0.26 0.26 0.26 0.16 0.22 0.20 0.00 0.00
0.32 0.32 0.26 0.00 0.02 0.10 0.00 0.00
0.01 0.03 0.05 0.07 0.09 0.1 0.5 1.0
Steering success rate
0.0 0.2 0.4 0.6 0.8 1.0
Top-K fraction of concept-sensitive attention heads