

Sycophancy (Single) · Single-Token Eval, Long-Form Steer · Token Matching

Qwen 1.5-14B

